Rapport de Collecte de Données

Projet ML : Prédiction de Survie Multi-Catastrophes Maritimes

Nouran GHALIOUNJI
M2 BIDABI

Février 2026

Table des matières

1. Vue d'ensemble 3
2. Sources de données 3
2.1 Titanic 3
2.2 Estonia 3
2.3 Lusitania 4
3. Évaluation de la qualité des données 5
3.1 Analyse des données manquantes 5
3.2 Analyse MNAR — Age Lusitania 5
4. Considérations éthiques 6

1. Vue d'ensemble

Ce rapport documente le processus de collecte de données pour le projet de prédiction de survie multi-catastrophes. Trois naufrages maritimes ont été sélectionnés, couvrant une période de plus de 80 ans (1912–1994), avec pour objectif explicite de tester la généralisation inter-domaine en présence de décalage de distribution.

Catastrophe	Année	Passagers/Équipage	Survivants	Taux de survie	Source
Titanic	1912	887	342	38,6 %	Kaggle
Lusitania	1915	1 964	769	39,2 %	rmslusitania.info (scraping)
Estonia	1994	989	137	13,9 %	Kaggle (archives Stanford)

2. Sources de données

2.1 Titanic

- **Source** : Kaggle — "Titanic: Machine Learning from Disaster"
- **URL** : https://www.kaggle.com/competitions/titanic
- **Date d'accès** : 2024
- **Format** : CSV (structuré)
- **Colonnes disponibles** : Survived, Pclass, Name, Sex, Age, Siblings/Spouses Aboard, Parents/Children Aboard, Fare
- **Qualité des données** : Élevée — manifeste complet des passagers avec informations socio-économiques. Aucune valeur manquante sauf Age (0 %). Fare disponible pour tous les passagers.
- **Considérations éthiques** : Il s'agit d'un jeu de données public largement utilisé contenant les noms et informations personnelles de vraies victimes. Les données sont utilisées strictement à des fins éducatives dans le cadre d'un projet de Master.

2.2 Estonia

- **Source** : Kaggle — liste des passagers du ferry Estonia (originalement issue des archives de l'Université de Stanford)
- **URL** : https://www.kaggle.com/datasets/christianlillelund/passenger-list-for-the-estonia-ferry-disaster
- **Date d'accès** : 2024

- **Format** : CSV (structuré)
- **Colonnes disponibles** : PassengerId, Country, Firstname, Lastname, Sex, Age, Category (P/C), Survived
- **Qualité des données** : Élevée — manifeste officiel des passagers et membres d'équipage issu de l'enquête suédo-estonienne. Aucune valeur manquante. Cependant, absence de variables socio-économiques (pas de tarif, pas de classe au-delà de la distinction Passager/Équipage).
- **Considérations éthiques** : La catastrophe de l'Estonia (1994) est relativement récente. Toutes les personnes listées sont décédées ou présumées mortes. Le jeu de données fait partie du dossier officiel d'enquête publique.

2.3 Lusitania

- **Source** : rmslusitania.info — scraping via Python (requests + BeautifulSoup)
- **URLs scrapées** :
  - https://www.rmslusitania.info/people/saloon/ (1ère classe)
  - https://www.rmslusitania.info/people/second-cabin/ (2ème classe)
  - https://www.rmslusitania.info/people/third-class/ (3ème classe)
  - https://www.rmslusitania.info/people/deck/ (équipage pont)
  - https://www.rmslusitania.info/people/victualling/ (équipage restauration)
  - https://www.rmslusitania.info/people/engineering/ (équipage technique)
  - https://www.rmslusitania.info/people/band/ (musiciens)
  - https://www.rmslusitania.info/people/stowaways/ (passagers clandestins)
- **Date d'accès** : 2024
- **Format** : Tableaux HTML convertis en CSV
- **Colonnes disponibles** : Name, Ticket number, Cabin number, Age, Citizenship, Residence, Lifeboat(s), Rescue vessel(s), Body, survived, category
- **Qualité des données** : Moyenne — taux de valeurs manquantes élevé sur plusieurs colonnes (Ticket : 85 %, Cabine : 86 %, Canot : 97 %, Corps : 86 %). Age manquant pour 30 % des passagers avec un pattern MNAR fort (équipage technique : 73 % manquant, équipage restauration : 70 % manquant contre 3 % pour la 1ère classe).
- **Considérations éthiques** : rmslusitania.info est une archive historique publique non commerciale. Le scraping a été réalisé à des fins de recherche académique uniquement, avec des délais appropriés entre les requêtes et sans contournement de contrôles d'accès.

3. Évaluation de la qualité des données

3.1 Analyse des données manquantes

Jeu de données	Variable	% manquant	Mécanisme	Traitement
Lusitania	Numéro de ticket	85,5 %	MCAR	Supprimé (seuil > 30 %)
Lusitania	Numéro de cabine	86,1 %	MCAR	Supprimé
Lusitania	Canot de sauvetage	97,7 %	MNAR	Supprimé
Lusitania	Navire de secours	97,8 %	MNAR	Supprimé
Lusitania	Numéro de corps	99,4 %	MCAR	Supprimé
Lusitania	Age	30,4 %	**MNAR**	Imputation par médiane conditionnelle par catégorie
Lusitania	Résidence	28,8 %	MAR	Supprimé (non utilisé comme feature)
Titanic	Age	0 %	—	Aucun traitement nécessaire
Estonia	Toutes colonnes	0 %	—	Aucun traitement nécessaire

3.2 Analyse MNAR — Age Lusitania

Un résultat critique de l'évaluation de la qualité est que les valeurs manquantes d'age dans le jeu de données Lusitania ne sont **pas manquantes aléatoirement (MNAR)**. Le taux de manque varie dramatiquement selon la catégorie :

- Équipage technique : **73,5 % manquant**
- Équipage restauration : **70,4 % manquant**
- Passagers 1ère classe : **3,1 % manquant**
- Passagers 3ème classe : **0,8 % manquant**

Ce pattern suggère que le processus d'enregistrement en 1915 notait systématiquement moins d'informations personnelles pour les membres d'équipage de statut inférieur. Une imputation globale par moyenne ou médiane introduirait un biais systématique. La solution adoptée est l'**imputation par médiane conditionnelle par catégorie**, qui respecte les distributions d'âge différentes au sein de chaque groupe.

3.3 Données manquantes structurelles

Plusieurs variables sont absentes pour des catastrophes entières, et non pour des individus spécifiques :

- **Fare** : Disponible uniquement pour le Titanic. Absent pour l'Estonia (non enregistré) et la Lusitania (non disponible dans la source scrapée).
- **Informations familiales** : Disponibles uniquement pour le Titanic (Siblings/Spouses Aboard, Parents/Children Aboard). Absentes pour l'Estonia et la Lusitania — ces jeux de données enregistrent des individus, pas des unités familiales.
- **Sexe** : Disponible pour le Titanic et l'Estonia. Pour la Lusitania, le sexe n'était pas enregistré dans la source et a été mis à "Not mentioned" pour les 1 964 passagers.

Ces absences structurelles représentent la principale source de décalage de covariance entre les jeux de données.

4. Considérations éthiques

4.1 Utilisation des données de victimes

Les trois jeux de données contiennent des informations personnelles (noms, âges, nationalités) de vraies personnes décédées ou survivantes de catastrophes maritimes. Les principes éthiques suivants ont été appliqués :

1. **Limitation de la finalité** : Les données sont utilisées exclusivement pour la recherche académique dans le cadre d'un Master en Machine Learning.
2. **Pas de ré-identification** : Aucune tentative de relier les individus entre les jeux de données ou d'identifier des proches vivants.
3. **Traitement respectueux** : L'analyse reconnaît que ce sont des registres de vraies tragédies humaines.
4. **Disponibilité publique** : Toutes les données ont été obtenues depuis des sources publiquement accessibles.

4.2 Éthique du scraping web

Le scraping de rmslusitania.info a été conduit avec :

- Des délais appropriés entre les requêtes pour éviter la surcharge du serveur
- Aucun contournement de contrôles d'accès ou de paywalls
- Aucune utilisation commerciale des données collectées
- Attribution à la source maintenue tout au long du projet

4.3 Biais dans les données historiques

Les données historiques de naufrages contiennent des biais systématiques qui reflètent les structures sociales de leur époque :

- Biais de genre : les femmes ont été priorisées pour les canots de sauvetage sur le Titanic (74 % de survie féminine contre 20 % masculine)
- Biais de classe : les passagers de 1ère classe avaient des taux de survie significativement plus élevés (63 % contre 24 % pour la 3ème classe)

Ces biais sont documentés et analysés dans le notebook d'évaluation plutôt que corrigés, car ils sont historiquement précis et le modèle est utilisé à des fins analytiques plutôt que décisionnelles.

5. Analyse du décalage de distribution

5.1 Trois façons dont les différences temporelles créent des problèmes de décalage

1. L'encodage du statut social change selon les époques

La notion de "classe" diffère fondamentalement entre les catastrophes. Sur le Titanic (1912), les 1ère/2ème/3ème classes impliquaient une séparation physique et sociale stricte à bord du navire. Sur l'Estonia (1994), la distinction est simplement Passager/Équipage sans hiérarchie de classe. Sur la Lusitania (1915), le système saloon/2ème cabine/3ème classe reflète le Titanic mais avec des proportions différentes et une dynamique de survie différente.

Solution technique adoptée : Harmonisation vers une variable travel_class unifiée, avec documentation explicite de la perte de granularité pour l'Estonia. *Compromis* : on perd la distinction entre différents types de passagers de l'Estonia au profit de la comparabilité inter-catastrophes.

2. La composition démographique des populations transportées change

L'Estonia transporte une population majoritairement nordique/baltique (Suède : 55,6 %, Estonia : 34,8 %) avec un âge moyen de 44,6 ans. Le Titanic transporte un mélange britannique/irlandais/américain avec un âge moyen de 29,5 ans. Ces différences démographiques signifient que les patterns appris sur une catastrophe (par exemple, l'association entre nationalité nordique et survie) ne se transfèrent pas aux autres.

Solution technique adoptée : Regroupement des nationalités en régions géographiques larges pour réduire la parcimonie tout en préservant le signal. *Compromis* : la nationalité reste fortement confondue avec l'identité de la catastrophe, ce que l'analyse de biais a confirmé.

3. Les mécanismes de survie eux-mêmes changent

Le mécanisme physique et social qui détermine la survie a changé radicalement sur 80 ans. Le Titanic a coulé en 2h40, permettant une évacuation organisée et l'application de normes sociales. La Lusitania a coulé en 18 minutes, ne laissant aucun temps pour une organisation. L'Estonia a coulé dans des mers agitées de nuit en 1994 avec un équipement de sécurité moderne

mais dans des conditions extrêmes. La relation fondamentale entre les features socio-démographiques et la survie n'est donc pas stable entre les catastrophes — c'est de la dérive conceptuelle (concept drift) plutôt que du décalage de covariance.

Solution technique adoptée : Entraînement de modèles séparés par catastrophe en complément du modèle global. *Compromis* : les modèles séparés ont moins de données d'entraînement, mais capturent mieux les mécanismes spécifiques à chaque contexte.

5.2 Pourquoi le simple regroupement produit de mauvais modèles

Concaténer simplement les trois jeux de données et entraîner un seul modèle produit des résultats trompeurs car :

1. **Le modèle apprend à identifier la catastrophe, pas les mécanismes de survie** : La variable nationality_region est fortement confondue avec l'identité de la catastrophe (nordic_baltic ≈ Estonia, uk_ireland ≈ Titanic/Lusitania). Le modèle exploite ce raccourci plutôt que d'apprendre les vraies causes de survie.
2. **L'absence structurelle de features crée un biais d'imputation systématique** : Fare est manquant pour 74 % du dataset poolé (Estonia + Lusitania sans Fare). Toute stratégie d'imputation introduit soit une erreur systématique, soit force le modèle à ignorer cette variable très prédictive.
3. **Le déséquilibre de classes varie selon les catastrophes** : Titanic : 38,6 % de survie, Lusitania : 39,2 %, Estonia : seulement 13,9 %. Le regroupement crée un dataset déséquilibré où le pattern dominant (faible survie de l'Estonia) écrase les signaux des autres catastrophes.

7. Statistiques du dataset final

Métrique	Valeur
Nombre total de lignes	3 840
Variables totales (brutes)	14
Variables utilisées en modélisation	7–11 (selon la stratégie)
Taux de survie global	32,5 %
Lignes Titanic	887 (23,1 %)
Métrique	Valeur

Métrique	Valeur
Lignes Lusitania	1 964 (51,1 %)
Lignes Estonia	989 (25,8 %)
Valeurs manquantes (dataset final)	Présentes uniquement dans Fare (Lusitania/Estonia) et nationality_region (Titanic)