Rapport Technique

Projet ML : Prédiction de Survie Multi-Catastrophes Maritimes

Nouran GHALIOUNJI
M2 BIDABI

Février 2026

Table des matières

Résumé Exécutif 3
1. Données et Ingénierie des Variables 3
1.1 Intégration des jeux de données 3
1.2 Décisions d'ingénierie des variables 4
2. Modélisation 5
2.1 Sélection des modèles 5
2.2 Pipeline de prétraitement 5
2.3 Stratégie 1 : Modèle global (Pooled) 6
2.4 Stratégie 2 : Modèles séparés 6
2.5 Modèle Titanic optimisé 7
3. Analyse de l'Importance des Variables 7
3.1 Comparaison des méthodes 7
4. Évaluation Critique et Généralisation 9
4.1 Design de l'expérience holdout 9
4.2 Résultats 9
4.3 Ce résultat est-il surprenant ? 9
4.4 Analyse du décalage de covariance 10
4.5 Métriques au-delà de l'accuracy 10
5. Analyse des Biais 11
5.1 Résultats du Disparate Impact Ratio 11
5.2 Biais dans les données vs amplification par le modèle 12
6. Le Paradoxe Éthique 13
6.1 Le paradoxe 13
6.2 Notre position : documentation transparente plutôt que neutralité artificielle 13
6.3 Actions concrètes 13
7. Limites 14
8. Conclusion et Recommandation de Déploiement 15

Résumé Exécutif

Ce projet construit un système de prédiction de survie sur trois catastrophes maritimes — le Titanic (1912), la Lusitania (1915) et l'Estonia (1994) — couvrant plus de 80 ans de données historiques. Le défi central n'est pas la prédiction en soi, mais la généralisation inter-domaine sous décalage de distribution : chaque catastrophe présente une disponibilité de données différente, des mécanismes de survie différents et des conventions d'enregistrement historiques différentes.

Deux stratégies d'entraînement ont été implémentées et comparées : un modèle global (pooled) entraîné sur toutes les catastrophes simultanément, et des modèles séparés entraînés par catastrophe. L'importance des variables a été analysée avec quatre méthodes complémentaires (importance par permutation, valeurs SHAP, coefficients de régression logistique, importance par suppression de colonne). La Lusitania a été réservée comme holdout hors-distribution pour mesurer la vraie généralisation. Enfin, une analyse complète des biais a été menée selon le genre, l'âge, la classe sociale et la nationalité, avec discussion du paradoxe éthique lié à la modélisation de patterns de survie historiquement discriminatoires.

Résultats clés :

- Meilleur modèle global (GradientBoosting, features réduites, seuil=0,35) : **ROC-AUC 0,757 — Recall 0,852 — F1 0,597**
- Meilleur modèle Titanic (GradientBoosting, seuil=0,50) : **ROC-AUC 0,860 — F1 0,776**
- Généralisation holdout (Lusitania) : **ROC-AUC ≈ 0,53** — quasi-aléatoire, confirmant la dérive conceptuelle
- Disparate Impact Ratio hommes vs femmes : **0,355** (très en dessous du seuil légal de 0,8)

1. Données et Ingénierie des Variables

1.1 Intégration des jeux de données

Trois jeux de données ont été intégrés dans un schéma unifié. Voir data_collection_report.md pour les détails complets des sources. Le défi principal est que chaque jeu de données a une structure différente reflétant son contexte historique et opérationnel :

- **Titanic** : jeu de données le plus riche avec des variables socio-économiques (Fare, Pclass), des informations familiales (SibSp, Parch) et des données complètes de sexe/âge pour 887 passagers
- **Estonia** : jeu de données démographique uniquement pour 989 passagers — âge, sexe, pays, catégorie (Passager/Équipage), sans tarif ni classe de cabine
- **Lusitania** : jeu de données scraping de 1 964 entrées avec taux élevé de valeurs manquantes, sexe non enregistré, catégorie disponible mais encodée différemment

1.2 Décisions d'ingénierie des variables

Groupes d'âge : L'âge brut a été converti en cinq catégories ordinales (Enfant ≤12, Ado 13–18, JeuneAdulte 19–35, Adulte 36–50, Senior 51+). Justification : (1) réduit le bruit lié à l'imputation de l'âge, (2) permet la comparabilité inter-catastrophes malgré les conventions d'enregistrement différentes, (3) capture la relation non-linéaire entre l'âge et la survie (enfants protégés, seniors à risque). L'âge brut est conservé mais exclu de la modélisation après création des groupes.

Connectivité sociale (group_size, has_group) : Pour le Titanic, dérivée de Siblings/Spouses Aboard + Parents/Children Aboard + 1. Pour l'Estonia et la Lusitania, les deux variables ont été fixées à 1 et 0 respectivement, les informations familiales n'étant pas enregistrées. Cela préserve la cohérence du schéma tout en représentant honnêtement la limitation des données. La variance nulle de group_size pour les catastrophes non-Titanic signifie que cette variable ne contribue effectivement que pour le Titanic — ce qui est documenté et accepté.

Harmonisation de la classe de voyage : Les systèmes de classe diffèrent entre catastrophes. Le mapping appliqué :

- Titanic (Pclass 1/2/3) → Première/Deuxième/Troisième
- Lusitania (saloon_1st/second_cabin_2nd/third_class_3rd/variantes équipage) → Première/Deuxième/Troisième/Équipage
- Estonia (P/C) → Passager/Équipage

Ce mapping perd de la granularité pour l'Estonia (pas de distinction entre différents types de passagers) et crée une catégorie "Passager" non comparable spécifique à l'Estonia. C'est une limitation connue qui contribue au décalage de distribution inter-catastrophes.

Région de nationalité : Les champs Citizenship/Country ont été normalisés en grandes régions géographiques (uk_ireland, usa, nordic_baltic, europe, latin_america, other). Cela réduit la parcimonie tout en préservant suffisamment de signal. Résultat important : nationality_region est fortement confondue avec l'identité de la catastrophe — les passagers nordic_baltic sont presque exclusivement des passagers de l'Estonia. Cela rend nationality_region peu fiable comme variable de généralisation, confirmé par le delta négatif lors de l'analyse column-drop (-0,006).

Variables contextuelles : Une table de contexte au niveau catastrophe a été créée et fusionnée avec les données individuelles. Variables : wartime (0/1), sea_state (ordinal 0–3), night (0/1), ship_size (ordinal 1–3), economic_importance (ordinal 1–3). Ces variables capturent les conditions au niveau de la catastrophe qui peuvent affecter la survie indépendamment des caractéristiques individuelles. En pratique, ces variables ont montré une importance par permutation quasi-nulle dans le modèle poolé et un delta quasi-nul dans l'analyse column-drop, car elles sont constantes au sein de chaque catastrophe — elles ne peuvent pas discriminer entre individus de la même catastrophe.

Traitement des données manquantes : L'âge de la Lusitania a été imputé par médiane conditionnelle par catégorie, justifié par l'analyse MNAR montrant que le taux de manque varie

de 3 % (1ère classe) à 74 % (équipage technique). Une imputation globale introduirait un biais. Le Fare a été laissé en NaN pour l'Estonia et la Lusitania, traité par SimpleImputer(strategy="median") dans le pipeline pendant l'entraînement.

2. Modélisation

2.1 Sélection des modèles

Quatre modèles de base ont été implémentés pour chaque stratégie d'entraînement :

Modèle	Pondération des classes	Justification
Régression Logistique	balanced	Baseline interprétable ; coefficients directement lisibles
Random Forest	balanced	Baseline ensembliste ; robuste aux valeurs aberrantes
Gradient Boosting	N/A (non supporté nativement)	Meilleur ROC-AUC dans les expériences préliminaires
SVM	balanced	Baseline non-linéaire

La pondération des classes a été appliquée à LogReg, RF et SVM pour compenser le déséquilibre de classes (particulièrement sévère pour l'Estonia : 13,9 % de survie). Le GradientBoosting ne supporte pas nativement class_weight — cette limitation a été compensée par un ajustement du seuil de décision après l'entraînement.

Note sur l'échec du SVM : Le SVM a produit une Précision et un Recall quasi-nuls sur le dataset poolé, indiquant une solution dégénérée. Cela est cohérent avec la sensibilité du SVM à la mise à l'échelle des variables et au déséquilibre de classes. Le modèle est conservé dans le tableau de comparaison pour l'exhaustivité mais exclu des analyses approfondies.

2.2 Pipeline de prétraitement

Tous les modèles utilisent un Pipeline sklearn avec prétraitement ColumnTransformer :

- Variables numériques : SimpleImputer(strategy="median")
- Variables catégorielles : SimpleImputer(strategy="constant", fill_value="Missing") + OneHotEncoder(handle_unknown="ignore")

La valeur de remplacement "Missing" pour l'imputation catégorielle a été délibérément choisie plutôt que la valeur la plus fréquente, car les données catégorielles manquantes (notamment nationality_region pour le Titanic) portent une information — ce sont des absences structurelles, pas une manque aléatoire.

2.3 Stratégie 1 : Modèle global (Pooled)

Les trois catastrophes ont été combinées en un seul ensemble d'entraînement. Découpage 80/20 train-test avec stratification sur Survived.

Résultats (tous les modèles, stratégie pooled) :

Modèle	Accuracy	Précision	Recall	F1	ROC-AUC
GradBoost	0,721	0,800	0,192	0,310	0,746
LogReg	0,632	0,464	0,856	0,602	0,724
RandomForest	0,608	0,448	0,872	0,592	0,724
SVM	~0,72	~0	~0	~0	~0,5

Le GradientBoosting atteint le meilleur ROC-AUC mais avec un Recall catastrophique de 0,192 au seuil par défaut. Cela reflète le déséquilibre de classes : le modèle optimise la log-loss et tend à prédire la classe majoritaire (non-survivant). La courbe d'apprentissage montre un surapprentissage initial qui diminue avec la taille du dataset, suggérant que le modèle bénéficierait de plus de données.

Réduction des variables : Sur la base des analyses SHAP, importance par permutation et column-drop, les variables à impact quasi-nul ou négatif ont été retirées : nationality_region, night, wartime, ship_size, has_group. Cela a réduit l'ensemble de variables de 11 à 7 tout en maintenant ou améliorant le ROC-AUC (0,756 vs 0,746).

Ajustement du seuil : Le seuil par défaut de 0,50 donnait Recall=0,19. Une recherche systématique a révélé que 0,35 optimise le F1 (0,597) avec Recall=0,852.

Modèle global final : GradientBoosting, 7 variables, seuil=0,35

- ROC-AUC : 0,757 | Précision : 0,460 | Recall : 0,852 | F1 : 0,597

2.4 Stratégie 2 : Modèles séparés

Un modèle a été entraîné indépendamment pour chaque catastrophe en utilisant uniquement les variables disponibles pour cette catastrophe. La suppression des colonnes 100 % NaN et des lignes avec valeurs manquantes a été appliquée par catastrophe.

Meilleur modèle par catastrophe :

Catastrophe	Meilleur modèle	Accuracy	Précision	Recall	F1	ROC-AUC
Titanic	GradBoost	0,854	0,831	0,783	0,806	0,859
Estonia	SVM	0,722	0,281	0,667	0,396	0,742

Catastrophe	Meilleur modèle	Accuracy	Précision	Recall	F1	ROC-AUC
Lusitania	RandomForest	0,509	0,403	~0,5	~0,45	~0,55

Le modèle Titanic est significativement meilleur que le modèle poolé, confirmant que les variables spécifiques au Titanic (notamment Fare) portent un signal fort qui est dilué dans le contexte poolé. Le modèle Estonia a un Recall élevé mais une Précision très faible — le fort déséquilibre de classes (13,9 % de survie) rend le compromis précision-rappel particulièrement critique. Le modèle Lusitania performe au niveau du hasard, cohérent avec l'hypothèse de dérive conceptuelle (naufrage en 18 minutes, aucune évacuation organisée possible).

Courbes d'apprentissage — Stratégie séparée :

- Titanic : Convergence saine — les courbes d'entraînement et validation se rapprochent, bonne généralisation
- Estonia : Écart modéré persistant — le modèle plafonne, limité par le pouvoir informatif des variables
- Lusitania : Grand écart persistant — fort surapprentissage, le modèle apprend des patterns spécifiques à l'entraînement qui ne généralisent pas

2.5 Modèle Titanic optimisé

L'analyse des variables pour le Titanic a confirmé que Sex, travel_class et Fare sont les variables dominantes. Un modèle réduit à 6 variables (Sex, travel_class, Fare, age_group, group_size, has_group) atteint un ROC-AUC légèrement supérieur à l'ensemble complet de variables :

Modèle	Accuracy	F1	ROC-AUC
Titanic complet	0,854	0,806	0,858
Titanic réduit	0,831	0,776	**0,860**

Le seuil de 0,50 a été conservé comme optimal pour le modèle Titanic — contrairement au modèle poolé, le modèle Titanic est déjà bien calibré, avec un F1 variant seulement de 0,761 à 0,776 entre les seuils 0,30 et 0,50.

3. Analyse de l'Importance des Variables

3.1 Comparaison des méthodes

Quatre méthodes ont été utilisées pour évaluer l'importance des variables, chacune avec des hypothèses et des modes d'échec différents :

Importance par permutation (agnostique au modèle, mesure la chute de ROC-AUC lors du mélange aléatoire d'une variable) :

- La plus fiable pour ce problème car elle opère dans l'espace des variables originales et mesure la contribution prédictive réelle
- Limitation : les variables corrélées partagent l'importance — si Sex et age_group sont corrélés, mélanger l'un capture partiellement l'autre
- Résultat : Sex > age_group > Fare > group_size, avec les variables contextuelles à quasi-zéro

Valeurs SHAP (TreeExplainer, opère dans l'espace transformé) :

- Fournit des informations directionnelles (cette variable pousse-t-elle la prédiction vers le haut ou vers le bas ?)
- Opère après prétraitement sur les variables one-hot encodées — donne une vision granulaire (ex : age_group_Senior spécifiquement vs age_group_Child)
- Limitation : les effets d'interaction sont distribués entre les variables, peut surestimer l'importance des variables avec de nombreuses catégories one-hot
- Résultat : age_group_Senior le plus négatif, Sex_female le plus positif, Fare avec un gradient continu

Coefficients de Régression Logistique (dans l'espace transformé) :

- Valable uniquement pour le modèle linéaire, pas directement comparable au GradBoost
- Utilisé comme vérification croisée d'interprétabilité, pas comme mesure d'importance principale
- Résultat : has_group coefficient positif le plus élevé (capturant probablement un signal spécifique au Titanic), travel_class_First fortement positif, age_group_Senior et Sex_male fortement négatifs

Importance par suppression de colonne (réentraînement sans chaque variable, mesure le delta de ROC-AUC) :

- Le plus coûteux en calcul mais le plus honnête — mesure la valeur marginale réelle de chaque variable
- Limitation : nécessite un réentraînement ; sensible à la corrélation des variables
- Résultat : age_group (+0,021), Sex (+0,019), Fare (+0,012) confirmés comme meilleures variables ; travel_class et nationality_region montrent un delta négatif (modèle meilleur sans elles)

Pourquoi les méthodes ne s'accordent pas : L'importance par permutation et le column-drop s'accordent sur le top 3. SHAP ajoute une information directionnelle. Les coefficients LogReg divergent (has_group classé 1er) car le modèle linéaire exploite has_group comme proxy indicateur du Titanic — has_group=1 signifie presque exclusivement un passager du Titanic.

C'est un problème classique de confusion que le GradBoost gère implicitement mais qui rend la comparaison directe des coefficients trompeuse.

Effets de la multicolinéarité : travel_class et Fare sont corrélés (les passagers de 1ère classe paient plus). Quand les deux sont présentes, le column-drop montre un delta négatif pour travel_class (-0,006) car Fare capture déjà son information. Supprimer travel_class ne nuit pas car Fare compense. Cela explique pourquoi travel_class apparaît comme importante dans SHAP (localement) mais montre un delta négatif en column-drop (globalement).

Quand la sélection automatique de variables nuirait : Une sélection automatisée basée sur le column-drop seul supprimerait travel_class. Cependant, pour le modèle spécifique au Titanic, travel_class porte une information supplémentaire au-delà de Fare (localisation physique sur le navire, accès au pont). Plus important, pour de futures catastrophes où les données de Fare ne sont pas disponibles mais où les données de classe le sont, conserver travel_class comme variable est essentiel pour l'applicabilité du modèle.

4. Évaluation Critique et Généralisation

4.1 Design de l'expérience holdout

La Lusitania a été sélectionnée comme holdout pour trois raisons :

1. Elle est la plus différente structurellement des catastrophes d'entraînement (pas de données de sexe, pas de Fare, naufrage en 18 minutes)
2. Elle a montré la pire performance dans la stratégie de modèles séparés (ROC-AUC ≈ 0,55)
3. Elle représente le test de généralisation le plus difficile

Le modèle a été entraîné sur Titanic + Estonia et évalué sans modification sur la Lusitania.

4.2 Résultats

Ensemble de variables	CV ROC-AUC	Holdout ROC-AUC	Gap
Stables uniquement (Sex, age_group, group_size)	0,764	0,533	+0,231
Économiques uniquement (Fare, travel_class)	0,751	0,507	+0,245
Toutes les variables	0,861	0,526	+0,335

ROC-AUC en validation croisée : 0,861 ± 0,011. ROC-AUC holdout : 0,526. Gap : 0,335.

4.3 Ce résultat est-il surprenant ?

Non. L'écart est attendu et a une explication structurelle claire. Le résultat diagnostique clé est que le gap est approximativement constant (~0,23) quelle que soit la combinaison de variables utilisée — même le modèle minimal avec seulement Sex et age_group montre un gap de 0,231. Cela exclut le décalage de covariance comme explication principale. Si l'écart était causé par

des distributions différentes de Fare/classe (décalage de covariance), le modèle avec les variables stables (Sex, age_group) aurait beaucoup mieux généralisé. Ce n'est pas le cas.

Le gap constant à travers tous les sous-ensembles de variables est la signature de la **dérive conceptuelle** : la relation entre les variables et la survie est fondamentalement différente sur la Lusitania. Sex est le prédicteur le plus fort sur le Titanic/Estonia (où "les femmes et les enfants d'abord" a été partiellement appliqué), mais sur la Lusitania, le naufrage en 18 minutes a empêché toute évacuation organisée basée sur le genre. Les mêmes variables portent une information prédictive différente selon le contexte.

4.4 Analyse du décalage de covariance

Bien que la dérive conceptuelle soit l'explication principale, le décalage de covariance est aussi présent :

- Fare : structurellement absent pour la Lusitania (100 % manquant)
- group_size : constant à 1 pour la Lusitania (aucune variance, aucun signal)
- Sex : 100 % "Not mentioned" pour la Lusitania — variable effectivement indisponible
- travel_class : distribution de catégories différente (plus d'Équipage dans la Lusitania que dans le Titanic)

L'interaction du décalage de covariance et de la dérive conceptuelle rend la généralisation à la Lusitania fondamentalement limitée. Aucun choix d'architecture de modèle ou d'ingénierie de variables ne peut récupérer du pouvoir prédictif quand les variables clés sont absentes et que le mécanisme de survie sous-jacent est différent.

4.5 Métriques au-delà de l'accuracy

L'accuracy est trompeuse pour les datasets déséquilibrés. Pour l'Estonia (13,9 % de survie), un modèle prédisant "aucun survivant" pour tout le monde atteint 86,1 % d'accuracy tout en étant complètement inutile. La hiérarchie de métriques suivante a été adoptée :

1. **ROC-AUC** : Métrique principale — mesure la capacité de discrimination indépendamment du seuil, robuste au déséquilibre de classes
2. **Recall (Sensibilité)** : Critique en contexte de survie — rater un survivant (Faux Négatif) est plus coûteux qu'une fausse alarme
3. **F1** : Moyenne harmonique, utile pour comparer les modèles quand précision et rappel comptent tous les deux
4. **Précision** : Secondaire — importante pour éviter de surcharger les prédictions de faux positifs
5. **Accuracy** : Rapportée pour l'exhaustivité mais non utilisée pour la sélection du modèle

5. Analyse des Biais

5.1 Résultats du Disparate Impact Ratio

Le Disparate Impact Ratio (DIR) = P(ŷ=1 | groupe) / P(ŷ=1 | groupe de référence). Un DIR < 0,8 indique une discrimination potentielle (règle des 4/5, standard EEOC).

Par genre (référence : femme) :

Groupe	N	Taux de survie réel	Taux prédit	DIR
Femme	800	32,5 %	33,0 %	1,000
Homme	1 076	20,4 %	11,7 %	**0,355**

Le modèle amplifie la disparité de genre au-delà des données historiques : écart réel = 12,1 pp, écart prédit = 21,3 pp. Le modèle pénalise les hommes plus sévèrement que les données ne le justifient (amplification = -0,087).

Par groupe d'âge (référence : Enfant) :

Groupe	DIR
Enfant	1,000
Ado	0,499
JeuneAdulte	0,357
Adulte	0,396
Senior	**0,070**

Le modèle surestime la survie des Enfants (+0,122 d'amplification) et sous-estime celle des JeunesAdultes (-0,104). Le sur-apprentissage de la règle "les enfants d'abord" depuis le Titanic en est probablement la cause.

Par classe de voyage (référence : Première) :

Groupe	DIR
Première	1,000
Deuxième	0,644
Troisième	0,321
Équipage	0,216
Passager	**0,014**

Le modèle ramène à quasi-zéro la survie prédite pour les Passagers (catégorie Estonia) — taux prédit 1,0 % contre 12,3 % réel. Il s'agit d'une amplification sévère du biais de classe spécifiquement pour la catégorie "Passager" de l'Estonia.

Par région de nationalité (référence : Not mentioned) :

Groupe	DIR
Not mentioned	**1,000**
europe	**0,229**
nordic_baltic	**0,091**
other	**0,000**

Le biais de nationalité est en partie un artefact de la confusion : les passagers nordic_baltic sont presque exclusivement des passagers de l'Estonia, qui ont un taux de survie de base faible (13,9 %). Le modèle utilise effectivement la nationalité comme identifiant de catastrophe, ce qui se traduit ensuite en prédictions de faible survie.

5.2 Biais dans les données vs amplification par le modèle

Variable	Biais historique dans les données	Amplification par le modèle	Verdict
Sexe	Oui (femmes 32,5 % vs hommes 20,4 %)	Oui, -8,7 pp pour les hommes	Amplifié
Âge (Enfant)	Oui (enfants 48,9 % de survie)	Oui, +12,2 pp	Amplifié
Classe voyage	Oui (1ère : 63 % vs 3ème : 24 %)	Oui, +8,8 pp pour 1ère	Amplifié
Nationalité	Partiellement (confondu avec la catastrophe)	Fortement, ~0 pour certains groupes	Artefact + amplifié

Un pattern cohérent émerge : **le modèle amplifie les inégalités existantes**. Les groupes déjà favorisés dans les données reçoivent des prédictions de survie plus élevées ; les groupes déjà défavorisés reçoivent des prédictions plus faibles. C'est caractéristique du gradient boosting entraîné sur des données déséquilibrées — le modèle devient très confiant sur les patterns majoritaires et sous-prédit la survie des groupes minoritaires.

6. Le Paradoxe Éthique

6.1 Le paradoxe

Un modèle de prédiction de survie entraîné sur les données du Titanic reproduira le pattern "les femmes et les enfants d'abord". Selon les standards modernes d'équité algorithmique (DIR < 0,8 pour tous les groupes), cela constitue une discrimination. Mais le pattern historique est précis. Un modèle qui élimine le biais de genre serait historiquement inexact.

6.2 Notre position : documentation transparente plutôt que neutralité artificielle

Nous défendons la position que le biais doit être **conservé dans le modèle mais documenté de façon exhaustive**, pour les raisons suivantes :

Argument technique : Supprimer Sex du modèle n'atteint pas l'équité — cela atteint un biais caché. Fare et travel_class sont corrélés avec Sex (les femmes en 1ère classe avaient la survie la plus élevée), et ces proxies continueraient à porter l'information de genre implicitement. Une modélisation vraiment respectueuse de l'équité nécessiterait un débiaisage adversarial ou un recalibrage post-traitement, ce qui dégraderait le ROC-AUC d'environ 2–3 points de pourcentage d'après notre analyse column-drop. Plus important, le DIR de 0,355 pour les hommes ne peut pas être remonté au-dessus de 0,8 sans distordre fondamentalement le registre historique.

Argument éthique : La finalité de ce modèle est l'analyse historique et la recherche académique, pas la prise de décision. Les risques éthiques qui motivent les standards d'équité algorithmique — des personnes réelles subissant des décisions défavorables basées sur des caractéristiques protégées — n'existent pas dans ce contexte. Aucune personne vivante ne se verra refuser un bénéfice ou une opportunité sur la base des prédictions de ce modèle.

Argument de transparence : Un modèle qui affiche un DIR=0,355 ouvertement est plus responsable éthiquement qu'un modèle qui dissimule la même disparité derrière des variables proxy. L'analyse documentée est elle-même la contribution éthique : elle montre où les données historiques amplifient les inégalités au-delà du registre historique, et elle délimite le périmètre légitime d'utilisation du modèle.

Ce que nous ne faisons pas : Nous ne recommandons pas ce modèle à des fins décisionnelles. Nous ne prétendons pas que les patterns historiques sont normativement acceptables. Nous ne généralisons pas à de futures catastrophes. Le modèle est un instrument analytique pour comprendre les patterns de mortalité historiques — rien de plus.

6.3 Actions concrètes

En cohérence avec cette position :

1. Tous les DIR calculés sont publiés sans les minimiser
2. Le biais dans les données et l'amplification algorithmique sont distingués explicitement
3. Toute utilisation de ce modèle doit être accompagnée de cette documentation complète

4. La généralisation à de futures catastrophes serait à la fois méthodologiquement non fiable (dérive conceptuelle démontrée) et éthiquement problématique sans réévaluation complète du contexte

7. Limites

1. **Données de sexe manquantes pour la Lusitania** : Le sexe est absent pour les 1 964 passagers de la Lusitania. Le modèle ne peut pas évaluer les patterns de survie basés sur le sexe pour la Lusitania, et toute affirmation inter-catastrophes sur le genre et la survie doit être qualifiée en conséquence.

2. **Granularité de classe pour l'Estonia** : Le binaire Passager/Équipage pour l'Estonia ne peut pas capturer les variations intra-classe qui peuvent avoir affecté la survie (l'équipage de pont vs l'équipage de salle des machines fait face à des conditions de survie différentes).

3. **La dérive conceptuelle rend la prédiction inter-catastrophes peu fiable** : L'expérience holdout démontre que le modèle généralise mal à de nouvelles catastrophes. Déployer ce modèle pour prédire la survie dans une nouvelle catastrophe maritime serait méthodologiquement injustifié.

4. **Variable group_size** : La variable de connectivité n'est significative que pour le Titanic. Son delta quasi-nul en column-drop pour le modèle poolé confirme qu'elle apporte une valeur de généralisation limitée malgré son importance dans le modèle spécifique au Titanic.

5. **Absence de tests de signification statistique** : Les comparaisons de modèles entre stratégies sont basées sur des estimations ponctuelles sans intervalles de confiance. Étant donné les ensembles de test relativement petits (notamment pour le Titanic : ~177 échantillons de test), les différences apparentes de performance peuvent ne pas être statistiquement significatives.

8. Conclusion et Recommandation de Déploiement

La conclusion centrale de ce projet est que **la survie dans les catastrophes maritimes n'est pas un phénomène stable et inter-domaine**. Les variables qui prédisent la survie sur le Titanic (genre, classe, tarif) portent un pouvoir prédictif différent sur l'Estonia (seuls le genre et l'âge comptent) et quasi-nul sur la Lusitania (aucune variable ne prédit fiablement la survie quand le naufrage dure 18 minutes).

Pour un déploiement dans un scénario réel :

- **Si le type de catastrophe est connu et similaire au Titanic** : Utiliser le modèle spécifique au Titanic (ROC-AUC 0,860, bien calibré). C'est le modèle le plus fiable du projet.
- **Si le type de catastrophe est inconnu** : Utiliser le modèle poolé avec seuil=0,35 comme baseline conservateur (ROC-AUC 0,757, Recall 0,852). Prioriser le Recall pour éviter de rater des survivants.
- **Pour des catastrophes similaires à l'Estonia ou à la Lusitania** : Aucun modèle de ce projet n'atteint des performances fiables. La collecte de données et un entraînement spécifique au domaine seraient nécessaires.

La recommandation technique la plus importante pour les travaux futurs est **la collecte de données Fare et de classe détaillée pour l'Estonia et la Lusitania**. L'absence de ces variables est le principal facteur de dégradation des performances dans le modèle poolé et la principale source d'incomparabilité inter-catastrophes.